

双分支融合策略优化方案

当前 **Dual-Branch** 融合采用简单的特征拼接加全连接，这种“等权”融合可能导致模型无法充分发挥强模态的优势，弱模态的噪声反而拖累性能^{1 2}。为提升 **transformer_three_stage_v3_plus** 的双分支融合表现，我们调研了主流多模态融合方法，并提出如下改进方案：

多模态异构特征融合优化

1. 注意力加权融合 (Attention/Gating Fusion)：与直接拼接不同，加入注意力门控机制，可根据每个分支特征对任务的贡献动态分配权重，实现“取长补短”³。具体做法是引入**融合注意力门**（Fusion Attention Gate）模块：首先分别对图像分支和特征分支的输出应用注意力权重，增强重要特征、抑制无关特征，然后再进行特征融合⁴。例如，可拼接两分支特征经过线性层得到两个 **gating 分数**，经softmax正则化得到权重 α 和 β ⁵。最终融合特征可表示为：

$$h_{\text{fusion}} = \alpha \cdot h_{\text{img}} + \beta \cdot h_{\text{feat}}$$

其中 h_{img} 、 h_{feat} 是可能经过投影后维度一致的两分支特征。通过这种注意力加权，模型能突出关键信息、抑制冗余噪声，相比简单拼接能显著提升融合效率²。已有研究表明，引入**门控机制**融合多模态特征能够考虑不同模态的重要性差异，使模型性能优于直接拼接平均³。本方案将设计可选的

FUSION_MODE（如“concat” / “attention” / “gate”）来切换融合策略。

2. 跨模态引导蒸馏 (Guided Knowledge Distillation)：当两分支模态存在强弱差异时，可采用知识蒸馏让“强模态”指导“弱模态”，提高后者表征能力⁶。具体而言，在训练过程中引入**互蒸馏损失**：以性能较强的分支为教师，约束较弱分支的输出分布或中间特征接近教师分支^{7 8}。例如，文本-音频情感识别研究中，文本模态强于视频/音频，采用文本特征蒸馏给音频/视频，显著增强弱模态表示⁶。蒸馏可在Dual-Branch模型内部进行（跨模态特征对齐），也可利用预先单模态训练好的教师网络指导双分支模型。在我们的问题中，可让图像分支和特征分支互相学习：提高弱分支对关键故障模式的敏感度，避免融合时简单平均弱化了强分支贡献。知识蒸馏配合注意力融合，能在包含弱模态的情况下仍保持整体性能稳定提升^{9 6}。

3. 模态交互增强 (Cross-Modal Interaction)：除了静态加权，可引入**交互式注意力机制**使两个分支特征充分交流，进一步挖掘互补信息。具体方案如**跨模态注意力 (Cross-Attention)** 或**交叉门控 (Cross-Modal Gating)**：令每个分支的特征通过注意力**查询**另一分支的信息，实现特征级别的互补。例如，可用图像分支特征作为Query、工程特征作为Key/Value，计算跨模态注意力，将另一模态中相关的上下文融合回来，反之亦然。医学影像分割中有类似设计：双编码分支通过**双模态交叉注意力**交换信息，融合时既保持各自细节又对齐互补语义¹⁰。这种**互注意**确保强模态为弱模态提供指导，同时弱模态有用信息也融入强模态表示，达到胜于各自单独学习的效果。总之，交互增强能进一步提升融合特征的判别力，使双分支融合“1+1>2”。

上述策略可结合使用：先经**跨模态交互**丰富特征，再通过**注意力门控**进行加权融合，最后输出融合表示^{4 11}。这套方案能够动态突出重要模态、弱化次要模态，实现真正的“取长补短”而非简单平均融合。

弱监督/伪标签场景下的融合方法

在Dual分支训练涉及伪标签和弱监督时，融合策略需考虑伪标签噪声及不确定性。例如，我们在阶段二用未标注数据生成伪标签并与测试数据联合训练Dual分支。这种情形下的主流做法有：

- **不确定性加权融合：** 针对伪标签可靠性不一的问题，可为每个数据点或每个模态预测分配置信权重。具体来说，引入**不确定度估计**模块，对伪标签置信度低的样本降低其在训练中的权重，防止伪标签错误被模型过度学习¹²¹³。例如，Dual Uncertainty模型通过**样本级不确定性筛选**剔除高风险伪标签，再用**像素级不确定性**指导多模型融合生成高质量伪标签，以提升半监督分割性能¹³。在本任务，可对Dual分支两支路输出的不一致或高不确定预测，减少其融合时的影响，从而“宁缺毋滥”地融合可靠信息。
- **双模型/双学生协同训练：** 可以训练两个不同初始化或结构的模型（对应Dual的两个子分支）互相生成伪标签，取交集或高置信部分监督彼此，提高伪标签质量。这类似于**协同训练(Co-training)**或**Dual-Student Mean Teacher**方法：两个学生网络从不同视角学习，对未标注样本输出需保持一致，从而利用彼此差异来校正伪标签¹⁴¹⁵。在我们的Dual架构下，可让CNN分支和MLP分支分别预测伪标签，只有双方都高置信的样本才用于更新；对于分歧样本，通过损失引导彼此靠拢。这样的双模型伪标签融合有助于提升弱监督训练的稳定性。
- **教师网络指导：** 也可在弱监督下引入预训教师。例如用全监督训练过的单分支模型生成伪标签，作为Dual分支训练的软标签，以缓解模型自身生成伪标签的偏差¹²。或者阶段二生成伪标签后，引入教师网络进行**可靠区域筛选**和**引导蒸馏**，只学习高可信度区域的伪标签。这些方法在医学影像等弱标注场景已证明有效，可以提高伪标签利用效率¹³。

综上，在Pseudo+Test联合训练的Dual分支中，应充分利用不确定性评估和多模型协同，避免简单将伪标签“一视同仁”融合。通过**自适应加权**和**伪标签筛选**，模型可更稳健地融合来自伪标签分支的信息，既获得额外知识又不被低质伪标签干扰。

融合策略对比分析：等权拼接 vs 注意力引导

当前融合策略（等权Concat+FC）： 将两分支特征直接拼接后通过全连接层融合。这种方法实现简单，但存在明显不足：其一，**特征冗余与噪声放大**——拼接后高维度特征可能包含重复甚至冲突信息，直接结合容易在小数据下过拟合，且噪声信息也被同等对待地传入下一层¹。其二，**无法区分模态贡献**——拼接并线性变换相当于静态融合，各模态特征在不同样本中的相对重要性未被显式建模，强模态的优势可能被弱模态稀释。例如，当工程特征分支信息较弱时，简单拼接仍会给予其与图像分支相等的地位，无法实现“扬长避短”。

改进融合策略（注意力门控/引导融合）： 新方案通过**注意力权重**和**门控单元**赋予模型选择权，让融合比例随内容自适应调整³。这样，当弱模态提供的信息较少或不可靠时，融合层会自动降低其权重；反之，如果弱模态带来补充线索也能被适当放大。这种**特征加权融合**能够**突出关键模态信息、抑制无关信息**，避免了简单拼接可能造成的信息淹没和噪声影响²。此外，引入**跨模态交互**和**知识蒸馏**进一步区别于纯粹的线性融合：交互机制让两个分支在融合前就互相“了解”，从而融合特征更加协调；知识蒸馏则平衡了强弱分支的表征差距，使最终融合特征更可靠。这些策略的组合已经在多模态任务中取得更高精度⁶。总而言之，相较于现有等权融合，新融合策略在理论上**降低了冗余噪声影响、提高了模态互补效率**，预期能明显改善Dual分支性能¹。

²。

验证集 (val) 使用方式评估

当前设置：阶段一将 train+val 合并作为无标签数据进行训练，阶段二生成伪标签，阶段三用 val 结合 test 评估模型表现（其中 val 属于已有标签数据的一部分）。并且由于严格标签规则，真正参与监督微调的只有 val（用于阈值选取和少量有标签训练），test 标签仅用于最终评估，不参与训练。

合理性分析：从主流方法论看，这种使用方式较为**非常规**，存在数据集划分不独立的问题：

- **将val用于无监督训练：**验证集通常用于模型选择和调参，应与训练过程（即使无监督）隔离开来，以保持评估公平。当前方案把 val 数据在阶段一当作无标签输入，虽然未用其标签，但模型已经“见过”这些数据的分布，可能导致对验证集的评估偏乐观（因为某种程度上算**Transductive Learning**）。主流半监督/无监督训练一般不会将验证集并入训练数据，而是仅用训练集（及可能额外未标数据）进行表示学习。
- **使用test数据参与训练：**更值得注意的是，test 数据被用于阶段1/2的无监督训练。严格来说，这违背了标准评价准则——测试集应完全独立于训练过程。如果模型在训练阶段已经访问了测试样本（哪怕无标签），就可能**泄露测试分布信息**，从而让最终在测试集上的评估不再完全可靠。通常除非明确采用跨域自训练等**transductive**设置，否则应避免在训练过程中使用测试集数据。
- **val+test共同评估：**把验证集和测试集混合评估也不常见。验证集本应用于模型调优，不应与测试结果混为一谈。如当前将 val 标签用于模型微调 and 阈值选定后，又将 val 与 test 一起报告性能，可能高估模型实际泛化能力。此外，val 经过微调已不再独立，相当于被“训练”过，再用来评估缺乏说服力。主流做法是：**验证集**仅用于选参数和早停，**测试集**单独用于报告最终性能。

改进建议：建议重新划分和使用 val/test：

- 在阶段一和阶段二的无监督训练中，**尽量只使用原始训练集(train)**和额外无标签数据，不要掺入 val/test。如果必须利用 val 无标签部分（比如数据量很少），也应意识到这是**非典型设置**，并在报告结果时注明。严格的方法是让模型对验证集“零触及”，从而 val 评估能客观反映模型对新数据的表现。
- **验证集仅用于模型选择和微调：**可以保留现有做法在阶段三用 val 做有监督微调 and 阈值选择，但**不要再将val并入最终评估**。模型微调后，直接在独立的测试集上评估性能指标，作为最终成绩。这样确保测试评估没有使用过的标签信息干扰，更符合主流评价标准。
- 如果担心 val 太小不足以微调和评估，可以考虑**扩充训练标注或交叉验证**。例如，将原 train 的一部分拿来标注用于半监督阶段三训练，其余作为留出的测试集。总之，应避免同时把一份数据既用于训练又用于评估。

综上，目前的 val 用法在严格意义上不太妥当。建议遵循**训练/验证/测试分离**原则：训练阶段（含无监督和伪标签生成）不应利用验证/测试数据；验证集只服务于调参和少量有监督训练；最终报告结果只针对未参与任何训练的测试集。适当调整这一策略有助于确保 Dual 分支训练和评估的**公平有效**。

代码修改方案

为实现以上融合改进，并保证与现有训练脚本 `continue_dual_training_v2.py` 和可视化对比脚本 `resume_and_compare.py` 无缝衔接，我们提出如下代码修改设计：

1. 引入可配置融合模块：在 `transformer_three_stage_v3_plus.py` 中增加双分支融合策略的模块化实现。可采用独立子模块形式，新建例如 `fusion_modules.py` 定义不同融合类，实现清晰协作：

- `ConcatFusion`：沿用原始等维拼接+全连接策略（输出512维），作为默认baseline保留。
- `AttentionFusion`：实现注意力融合。包含可学习参数用于计算两个分支特征的权重，例如使用一个两层MLP将 `[h_img; h_feat]` 映射为2个 **gating分数**，再经softmax得到权重 α, β ⁵。再将 h_{img} 和 h_{feat} 投影到同维度后按 α, β 加权求和得到融合特征。
- `GatedFusion`：实现门控机制融合。可采用**交叉门控**：比如通过一个Sigmoid门控网络，利用一支的特征去生成另一支的通道权重： $g_{img} = \sigma(W_z h_{feat})$, $g_{feat} = \sigma(W_i h_{img})$ ，然后 $h_{img}' = h_{img} \odot g_{img}$; $h_{feat}' = h_{feat} \odot g_{feat}$ （逐通道相乘），最后再将 h_{img}' 和 h_{feat}' 拼接或相加融合。从实现上，也可简化为对每支输出一个标量权重： $w_{img}, w_{feat} = \text{Sigmoid}(W[h_{img}; h_{feat}])$ ，融合 $= w_{img} \odot h_{img} + (1 - w_{img}) \odot h_{feat}$ （需预先投射到同维）³。这种门控在代码上可以通过Linear层+Sigmoid得到权重，再进行element-wise乘法实现。

修改步骤：

```
# 伪代码示例：在 BranchEncoder 中集成新的融合策略
class BranchEncoder(nn.Module):
    def __init__(self, cfg):
        ...
        if self.branch_mode == 'dual':
            # 初始化两个子分支
            self.hetero_branch = HeteroCNN(output_dim=cfg.CNN_FEAT_DIM)
            self.zerone_branch = ZeroneMLP(input_dim=cfg.ZERONE_DIM,
            output_dim=cfg.MLP_FEAT_DIM)
            # 根据FUSION_MODE选择融合模块
            if cfg.FUSION_MODE == 'concat':
                self.fusion_module = ConcatFusion(cfg.CNN_FEAT_DIM, cfg.MLP_FEAT_DIM,
            out_dim=512)
            elif cfg.FUSION_MODE == 'attention':
                self.fusion_module = AttentionFusion(cfg.CNN_FEAT_DIM, cfg.MLP_FEAT_DIM,
            out_dim=512)
            elif cfg.FUSION_MODE == 'gate':
                self.fusion_module = GatedFusion(cfg.CNN_FEAT_DIM, cfg.MLP_FEAT_DIM,
            out_dim=512)
            ...
        def forward(self, image, zerone):
            if self.branch_mode == 'dual':
                h_img = self.hetero_branch(image) # shape: (B, 512)
                h_feat = self.zerone_branch(zerone) # shape: (B, 256)
                h_fused = self.fusion_module(h_img, h_feat) # 输出shape (B, 512)
                return h_fused
            elif self.branch_mode == 'hetero':
                return self.hetero_branch(image)
            elif self.branch_mode == 'zerone':
                ...
```

上述设计确保：**(a)** `fusion_module` 的输出统一为512维，与原concat方式保持一致，不影响后续SVDD投影头和分类器结构；**(b)** 通过配置项 `cfg.FUSION_MODE` 控制使用哪种融合逻辑，默认仍为“concat”，以保持与之

前版本兼容。新的 `AttentionFusion` / `GatedFusion` 类需要在初始化时根据输入维度构建内部权重计算层，在 `forward` 方法中实现上述权重计算和特征融合逻辑。

2. 保留与扩展可视化功能： 修改过程中将确保原有可视化接口不受破坏。例如，`BranchEncoder.forward` 输出保持不变（Dual仍输出融合后特征 `h`），因此 `VisualizationManager` 中用于特征相关性、TSNE可视化的部分无需修改。但我们建议**扩展新的可视化**以分析融合行为：

- **门控权重可视化：** 在使用注意力/门控融合时，模型为每个样本计算的分支权重 α, β 是理解融合效果的关键指标。可在训练过程中将平均权重随epoch变化记录到日志，或在验证集上对正常/故障样本分别统计权重分布，并通过柱状图或折线图绘制。【例如，可视化结果可能显示故障样本更依赖图像分支（ α 较高），正常样本则两个分支权重相对均衡】。这将直观展示模型如何“取长补短”。
- **特征分布与判别力：** 借助已有的 t-SNE、PCA 可视化，将改进后的Dual融合特征与原Hetero/Zerone单分支特征在二维投影中对比，查看融合后类别分离是否更明显。也可绘制**特征相关性热图**比较融合前后特征冗余是否降低。适当增加这些可视化，有助于证明新融合策略有效整合了模态优点。

实现上，可在 `VisualizationManager` 增加对 `cfg.FUSION_MODE` 的判断：当使用attention/gate时，调用模型前向过程中返回的门控权重（需要在前向 `result` 字典中返回权重向量）用于可视化。例如，将权重随批次求平均记录，最后绘制曲线。同时，在Resume对比时，将Dual的新性能与原Dual baseline对比，展示性能提升。

3. 注释和文档完善： 在代码中添加/修改注释时，保持中英双语风格，解释新的融合逻辑与参数含义。例如：

```
# 在 AttentionFusion.forward 中示例:
def forward(self, h_img, h_feat):
    # 计算融合权重 (例如使用 concat后的注意力机制)
    concat_feat = torch.cat([h_img, h_feat], dim=1) # 拼接图像和工程特征
    scores = self.gating_mlp(concat_feat) # 通过两层感知机获得注意力分数
    weights = torch.softmax(scores, dim=1) # 转换为 2 个模态权重 ( $\alpha, \beta$ )
    # 根据权重加权求和融合
    h_img_proj = self.proj_img(h_img) # 将 h_img 投影到统一维度
    h_feat_proj = self.proj_feat(h_feat)
    h_fused = weights[:,0:1]*h_img_proj + weights[:,1:2]*h_feat_proj
    return h_fused
```

上述注释清楚描述了每步操作含义，方便中英文读者理解。类似地，在 `GatedFusion` 等模块也应增加注释说明其门控策略。此外，在README或代码头部文档中总结**Dual融合新方案**的设计思路和使用方法（例如：可通过命令行参数 `--fusion_mode attention` 切换融合策略），确保使用者明确改动内容。

4. 与训练流程的衔接： 新增的融合模块对外接口与原始模型一致，因此 `continue_dual_training_v2.py` 中的训练流程无需改动，只需确保在初始化配置或命令行参数中设置所需的 `FUSION_MODE`（默认“concat”保持不变，用户可选“attention”或“gate”）。保存和加载模型时，由于增加了新的子模块参数，需注意使用与训练相同的配置初始化模型，再load状态字典，以避免缺少参数报错。不过我们保持了相同类名和结构(在 `BranchEncoder`内封装)，因此checkpoint兼容性不受影响。`resume_and_compare.py` 在对比各支线时，会分别初始化hetero/zerone/dual分支模型，多了 `FUSION_MODE` 后默认Dual仍为concat，如果要比较新老融合效果，可运行两次Dual（或在配置中增加多种fusion模式评估功能）。我们也可扩展对比脚本使其能在Dual分支下同时跑多种融合策略的实验，生成对比图表，以量化新融合对性能的提升。

综上，按照上述方案修改后，Dual分支融合逻辑将更加智能：通过注意力门控动态平衡两模态贡献，并结合知识蒸馏和交互机制提升弱模态表征。在保证与既有代码兼容的前提下，我们提供了详尽的代码实现思路和注释说明，并加强了可视化以验证新策略效果。新的融合模块将更充分发挥“双模态互补”潜力，有望显著改善变压器振动故障诊断任务的性能^{6 4}。各关键设计要点和改进均已在文中阐明，后续可据此实施代码修改并进行实验验证。

参考文献：

【11】Wang et al. (2023). Dual-Branch Network with Hybrid Attention for Multimodal Ophthalmic Diagnosis – 讨论了传统特征拼接存在维度叠加导致过拟合、冗余信息放大的问题，提出融合注意力门控和多尺度注意力来加权融合多模态特征^{1 4}。

【15】Li et al. (2025). Multi-modal Anchor Gated Transformer with Knowledge Distillation – 提出了在多模态情感识别中先用知识蒸馏增强弱模态表示，再通过锚点式门控Transformer融合，提高模型即使包含最弱模态仍保持稳定性能^{9 6}。

【16】Qiu et al. (2024). Dual uncertainty-guided multi-model pseudo-label learning – 针对半监督伪标签噪声问题，引入样本/像素双重不确定性度量筛选高质量伪标签，确保训练平稳^{12 13}。

【17】Zhang et al. (2024). MHPC-Net: dual-branch encoder and multi-scale cross attention fusion – 提出在有限标注下，用双分支编码配合跨模态注意力融合CT和MRI信息的网络，通过空间权重和双模态交互增强特征互补，提升分割性能¹⁰。

【24】Wang et al. (2025). A Cross-Attention Gating Mechanism-Based Multimodal Feature Fusion – 提出针对软件缺陷预测的多模态融合方法，对比了拼接、相加和门控等策略，发现简单拼接/相加无法突出关键信息，加入门控机制可在特征融合时区别不同模态贡献，性能显著提升^{3 2}。

^{1 4 11} Dual-Branch Network with Hybrid Attention for Multimodal Ophthalmic Diagnosis

<https://www.mdpi.com/2306-5354/12/6/565>

^{2 3 5} A Cross-Attention Gating Mechanism-Based Multimodal Feature Fusion Method for Software Defect Prediction | MDPI

<https://www.mdpi.com/2076-3417/15/20/11259>

^{6 7 8 9} Multi-modal Anchor Gated Transformer with Knowledge Distillation for Emotion Recognition in Conversation

<https://arxiv.org/html/2506.18716v1>

^{10 12 13 14 15} (PDF) Dual uncertainty-guided multi-model pseudo-label learning for semi-supervised medical image segmentation

https://www.researchgate.net/publication/377629753_Dual_uncertainty-guided_multi-model_pseudo-label_learning_for_semi-supervised_medical_image_segmentation